

# Лаборатория: поймите статистику, которая врёт

**14:30-17:00.** В 17:00 каждый показывает одно своё открытие.

Сегодня вы не считаете формулы, это делает машина. Вы решаете, **можно ли верить числу**. Среднее, корреляция, «значимый» результат, всё это умеет врать. Ваша задача: поймать вранье и доказать, что это вранье. Данные берите свои, вчерашний датасет с Kaggle, или один из встроенных в seaborn (*titanic*, *penguins*, *tips*). Чем интереснее вам данные, тем живее пойдёт расследование.

● костяк, через него проходят все ○ если идёт легко, берите по пути

## Минимум, до него доходят все

- 1 Допросите одну колонку.** Попросите Claude Code посчитать среднее, медиану, стандартное отклонение и квантили. Не глядите на это как на формальность: где среднее расходится с медианой (значит, есть перекос)? Большой ли разброс? Что это говорит о данных?
- 2 Одна корреляция.** Выберите две величины, посчитайте Pearson  $r$ . Вынесите вердикт: связь настоящая или совпадение? И сразу напомните себе, что корреляция, это ещё не причинность.
- 3 Проверьте руками.** Сверьте один вывод на маленьком куске данных. Машина сказала, вы подтвердили. *Дошли до этого, у вас уже есть результат, который не стыдно показать.*

## Куда копать, сколько угодно

- 4 Форма.** Постройте распределение колонки: оно нормальное? есть два горба? где сидит выброс, которого не видно по среднему?
- 5 z-score.** Стандартизуйте колонку и вытащите точки, где  $|z|$  больше 2 или 3. Это ваши кандидаты в аномалии.
- 6 Среднее, которое врёт.** Найдите среднюю по малому числу строк, или с одним выбросом, или ту, что переворачивается при разрезе по группе (парадокс Симпсона).
- 7 Сместите выборку.** Возьмите заведомо кривой кусок данных и покажите, как от этого поехала статистика. Кто молча выпал из картины?
- 8 Сравните две группы.** Прогоните t-тест через агента, получите p-value, и усомнитесь: эффект правда большой или просто «значимый»?
- 9 Мини-расследование.** Соберите пять проверенных наблюдений, каждое по схеме: вопрос, число, проверка.

## 🕒 Особый вызов: охота на призрак

Попросите Claude Code сгенерить случайные, **заведомо не связанные** колонки. Переберите пары и найдите «впечатляющую» корреляцию или «значимое» различие, которое на самом деле чистый шум. Покажите ловушку: вот цифра, которая убеждает, и вот почему она ничего не значит. Это **p-hacking**, и это статистическое ядро того, почему модели переобучаются, а  $R^2 = 0.99$  умеет врать. Самое ценное открытие дня, это не то, что данные сказали, а то, где они чуть вас не обманули.

## Три привычки детектива

- 1** Сначала угадайте ответ, потом запускайте. Там, где вы промахнулись, и прячется самое интересное.
- 2** К каждому числу задавайте вопрос: по скольким строкам оно посчитано и нет ли там пропусков?
- 3** Любой вывод агента сверяйте руками на маленьком куске. Запустилось, это ещё не значит, что правда.

## В 17:00

Каждый показывает одно открытие за 30 секунд. Не «я посчитал среднее», а так: «я нашёл вот это, и вот как проверил, что это правда, а не артефакт». Одно число, одна проверка, и всем всё понятно.

**Формулы считает машина. За вами остаётся скепсис.**