


Парадокс Симпсона

Связь, которая видна в каждой группе, переворачивается, когда группы смешать в одну кучу.



Часы и зарплата у выпускников

по всем сразу: $r = -0.32$

внутри каждого трека:

$+0.88$

Почему так

Виноват скрытый третий фактор, здесь это трек. Аналитики работают мало часов и получают много, мобильщики наоборот. Лесенка между треками и переворачивает общий знак.

Реальный пример: приём в Беркли, 1973. По вузу женщин брали реже, а по факультетам наравне или чаще. Скрытый фактор это факультет.

p-hacking: охота на призрак

Переберите достаточно гипотез, и что-то всегда выскочит «значимым», даже в чисто шуме.

20 проверок на случайных данных

ns	ns	ns	ns	ns
ns	ns	ns	ns	ns
ns	ns	p=.03	ns	ns
ns	ns	ns	ns	ns

*при пороге 0.05 примерно 1 из 20 случайностей
проходит как «значимая»*

В нашем датасете

8 случайных колонок, 28 пар. Две прошли порог, лучшая **r=0.15**, **p=0.027**. Связи там нет по построению.

Связь с ML: то же самое ядро у переобучения. Подгони под шум, и $R^2 = 0.99$ на обучении окажется пустышкой на новых данных.

Защита: сначала гипотеза, потом данные; проверка на отложенной выборке; поправка на число сравнений.