

Можно ли верить вашей модели?

Регрессия на реальных данных: от EDA до честного вердикта

Сценарий. Вы junior-аналитик. Заказчик приносит датасет и просит: «Постройте модель, которая предсказывает **целевую величину**, и скажите честно, насколько ей можно верить». Ваша задача не выдать красивый R^2 , а доказать, где модель надёжна, а где врёт. Сегодняшняя линия дня: **не верь числу на слово, проверь**.

Что нужно сделать

- Взять **регрессионный** датасет (цель непрерывная, это не классификация) с Kaggle или UCI ML Repository.
- Сделать **EDA**: размер, типы, пропуски, `describe()`, распределение цели, корреляции, 2–3 ключевых графика. Отметить ловушки (перекося, выбросы, пропуски).
- Построить **базовую модель**: разбиение train/test, масштабирование признаков, `LinearRegression`, метрики **на тесте**.
- Применить новые методы главы 4: **полином** и/или регуляризацию (**Ridge / Lasso / ElasticNet**), сравнить модели на тесте (проверить градиентный спуск).
- Поставить диагноз: **кривые обучения** или график остатков, недообучение это или переобучение.
- Дать **вердикт**: RMSE в контексте среднего значения цели, где модель ошибается, какую модель выбрали и почему.

Тайминг (14:30 – 16:30)

Время	Этап	Что должно получиться
14:30–14:45	Данные и задача	Выбран датасет, непрерывная цель, одна фраза: что и для кого предсказываем.
14:45–15:10	EDA	Размер, типы, пропуски, распределение цели, корреляции, 2–3 графика, список замеченных ловушек.
15:10–15:35	Базовая модель	train/test split, <code>StandardScaler</code> , <code>LinearRegression</code> , метрики на тесте, график остатков.
15:35–16:05	Улучшение и проверка	Полином и/или Ridge/Lasso/ElasticNet, сравнение на тесте, кривые обучения, интерпретация коэффициентов.
16:05–16:20	Вывод	RMSE против среднего цели, где модель врёт, выбор лучшей модели с обоснованием.
16:20–16:30	Подготовка защиты	Подготовка и репетиция, чтобы уложиться в 3 минуты.

Датасеты на выбор

Можно взять любой регрессионный набор с Kaggle или UCI (<https://archive.ics.uci.edu/>), цель обязательно непрерывная. Если не хотите тратить время на поиск, берите из списка:

- California Housing**, цена жилья (есть у нас, `housing.csv`).
 - Medical Cost (Insurance)**, страховые расходы (Kaggle).
 - Bike Sharing Demand**, число аренд (UCI).
- Auto MPG**, расход топлива (UCI).
 - Concrete Strength**, прочность бетона (UCI).
 - Wine Quality**, оценка качества (UCI).

Что показать на защите (3 минуты)

Время	Что говорите и показываете
~30 сек	Задача и данные. Что предсказываем и для кого, размер набора, главный признак.
~45 сек	EDA. Один график плюс главная находка или ловушка (перекося, выброс, пропуски, странная корреляция).
~60 сек	Модели и честная оценка. Метрики на тесте (RMSE, R ²), сравнение базовой модели с полиномом или регуляризацией, одна кривая обучения или график остатков.
~45 сек	Вердикт. Можно ли верить модели? RMSE в контексте среднего значения цели, где модель ошибается, что бы улучшить.

Claude Code: помощник, а не автопилот

Промпты пишете по-английски, копируете и адаптируете под свой датасет. Стартовые шаблоны:

1. EDA
Load <dataset>.csv with pandas. Show shape, dtypes, missing values, and describe().
Plot the distribution of the target <target> and a correlation heatmap.
Find the 3 features most correlated with the target and scatter-plot them.
Flag any skew, outliers, or non-random missing data.

2. Базовая модель (честная оценка)
Split into train/test (test_size=0.2, random_state=42).
Build a pipeline: SimpleImputer(median), StandardScaler, LinearRegression. Fit on train.
Report MAE, MSE, RMSE and R2 ON THE TEST SET only.
Plot predicted vs actual, and a histogram of residuals.

3. Улучшение и диагностика
On the same train/test split, compare three models: plain LinearRegression, polynomial regression (PolynomialFeatures degree=2 or 3 + StandardScaler), and Ridge or Lasso. Show a table of test RMSE and R2 for each.
Plot learning curves for the best and the worst model to diagnose under/overfitting.

4. Вердикт
Compare the best model RMSE to the mean and std of the target.
Show the 5 cases with the largest residuals.
In plain language, state where the model is reliable and where it fails.

Важно. Claude Code пишет код, но отвечаете вы. На защите спросим, откуда взялось любое число. Если не можете объяснить, что такое ваш R² или почему выбрали Ridge, это не зачтётся. Читайте код, который он выдал, и сверяйте цифры.

Чего избегать (типичные обманы себя)

- Показывать метрики на обучающем наборе вместо тестового.
 - Вообще не делать train/test split.
 - Верить высокому R² без остатков и кривых обучения.
- Брать метрики классификации (accuracy) для регрессии.
 - Регуляризовать без масштабирования признаков.
 - Сказать «модель хорошая», не сравнив RMSE со средним цели.

Как оцениваем

Доля	Критерий
25%	EDA и понимание данных: нашли структуру, ловушки, главные признаки.
25%	Честная оценка: train/test, масштабирование, метрики на тесте.
25%	Новые методы: полином или регуляризация плюс диагностика (кривые обучения или остатки).
15%	Вердикт и интерпретация: можно ли верить, где ошибается, обоснован выбор модели.
10%	Выступление: уложились в 3 минуты, ясно и по делу.