

YDL 2026, Неделя 2, День 3. Командное задание

От «у нас нет ответов» к «у нас есть модель»

Сегодня вы прошли два мира: обучение с учителем (есть метка, учим предсказывать) и обучение без учителя (метки нет, ищем структуру сами). Это задание соединяет их в одну цепочку на реальных данных.

Легенда: вам выдали набор данных без целевого столбца. Никто не сказал, на какие группы делятся объекты. Ваша работа, как аналитиков, найти эти группы, превратить их в метку и проверить, можно ли потом эту метку предсказывать. В конце вы должны честно сказать, получились ли группы осмысленными, а не просто разноцветными точками.

Состав команд и регламент

- 4 команды, датасет закреплён за командой (3 распределяются случайно, HAR отдаётся самой подготовленной команде).
- Работа: 14:30 – 16:30 (2 часа).
- Выступления: с 16:30, по 10 минут рассказ плюс 5 минут на вопросы.
- Один ноутбук на команду, выступают все по очереди (каждый отвечает за свой шаг цепочки).

Датасеты команд

Каждой команде достаётся один набор данных без готовой целевой метки. Метку вы создаёте сами на шаге 3.

1. Country Data, помощь странам

Социально-экономические и медицинские показатели 167 стран: детская смертность, экспорт, импорт, расходы на здоровье, доход, инфляция, продолжительность жизни, рождаемость, ВВП на душу (9 числовых признаков).

Легенда: вы консультанты гуманитарного фонда, надо решить, каким странам направить помощь. Кластеризация делит страны на группы по уровню развития, прогнозный столбец это и есть «уровень развития».

kaggle.com/datasets/rohan0301/unsupervised-learning-on-country-data

2. Wholesale Customers, сегменты клиентов

440 клиентов оптового дистрибьютора, годовые траты по категориям: Fresh, Milk, Grocery, Frozen, Detergents_Paper, Delicassen (6 числовых признаков). Сегменты интерпретируются как «HoReCa против ритейла». PCA здесь нужен, чтобы увидеть шестимерные траты на плоскости.

archive.ics.uci.edu/dataset/292/wholesale+customers

3. Seeds, зёрна пшеницы

210 зёрен трёх сортов (Kama, Rosa, Canadian), 7 геометрических признаков: площадь, периметр, компактность, длина и ширина зерна, коэффициент асимметрии, длина бороздки. Важно: в данных есть настоящий сорт, но при кластеризации его НЕ используют, его прячут. Сорт открывают только в конце, чтобы проверить, угадала ли кластеризация реальные классы. Обычно совпадает не всё, около 8% зёрен попадают не в свой кластер, и это честный вывод: геометрии зерна не всегда достаточно, чтобы отличить сорт. Ровно принцип «не верь, проверь».

archive.ics.uci.edu/dataset/236/seeds

4. Human Activity Recognition (HAR), усиленный вариант

Данные с акселерометра и гироскопа смартфона на поясе, 561 признак, шесть активностей (ходьба, подъём и спуск по лестнице, сидя, стоя, лёжа), 30 человек. PCA здесь раскрывается в полную силу: сжимает сотни признаков до нескольких. Набор тяжёлый, данные разнесены по нескольким файлам, поэтому он отдаётся самой подготовленной команде.

archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones

Цепочка работы (5 шагов)

Шаг 1. EDA и подготовка

Посмотрите на данные раньше, чем на модели. Сколько объектов и признаков, какие масштабы, есть ли пропуски и выбросы. Постройте распределения и матрицу корреляций. Признаки в разных масштабах обязательно приведите к одному масштабу (StandardScaler), иначе и кластеризация, и PCA дадут искажённую картину: признак с большими числами перетянет всё на себя. Зафиксируйте одну находку, которая вас удивила. Её покажете на выступлении.

Шаг 2. Кластеризация (kmeans)

Меток нет, поэтому структуру ищем сами. Запустите kmeans на масштабированных данных. Число кластеров k не угадывайте: постройте метод локтя (inertia от k) и коэффициент силуэта, выберите k по ним и объясните выбор. Не верьте первому k на слово, проверьте соседние значения.

Шаг 3. Создание прогнозного столбца

Номера кластеров, которые выдал kmeans, это и есть ваша новая метка. Добавьте её отдельным столбцом в таблицу. С этого момента у вас появилась цель, которой не было в исходных данных: вы её сконструировали. Дайте кластерам человеческие имена по их средним признакам (например, «высокий доход, низкие траты»), а не «кластер

0, кластер 1». Имя должно объяснять, чем группа отличается от других.

Шаг 4. PCA для проверки

У вас много признаков, глазом их сразу не увидеть. Сожмите данные до двух главных компонент (PCA) и нарисуйте объекты на плоскости, раскрасив их по метке из шага 3. Посмотрите, отделяются ли кластеры визуально или налезает друг на друга. Отметьте, какую долю дисперсии удержали две компоненты: если мало, двумерная картинка обманчива, и это тоже вывод.

Шаг 5. Классификация

Теперь проверка, что метка не случайна. Обучите классификатор (начните с логистической регрессии или KNN) предсказывать вашу метку из шага 3 по исходным признакам. Разделите данные на train и test, посчитайте accuracy, precision, recall, F1. Если классификатор уверенно учит границы между кластерами, значит группы реальные и разделимы. Если метрики низкие, честно скажите: кластеризация дала размытые группы.

Команде Seeds: предсказывайте именно свою kmeans-метку из шага 3, а не настоящий сорт. Настоящий сорт достаньте отдельно и сравните с вашими кластерами (например, таблицей соответствия): совпали ли группы с реальными сортами и где кластеризация ошиблась.

Что сдать и что показать

Сдать (ноутбук) до начала выступлений:

- весь путь от EDA до классификации с выводами по каждому шагу;
- графики: распределения, метод локтя или силуэт, проекция PCA с раскраской по кластерам, метрики классификатора.

Показать на выступлении (10 минут, 3 опорные мысли):

1. Данные и одна находка EDA, которая повлияла на работу.
2. Сколько кластеров выбрали и почему, как назвали группы, как они выглядят на проекции PCA.
3. Насколько хорошо классификатор предсказывает вашу метку, и ваш честный вердикт: получились группы осмысленными или нет.

Критерии (на что смотрим)

- Данные приведены к одному масштабу перед kmeans и PCA.
- Число кластеров выбрано по локтю или силуэту, а не наугад.
- Кластеры названы по смыслу, а не номерами.
- Указана доля дисперсии, удержанная двумя компонентами PCA.
- Метрики классификатора честные (train и test), вывод соответствует числам.
- Вывод команды: подтвердилась структура данных или нет.